1 Introduction

Bernoulli Random Variable

$$p(x) = \begin{cases} 1-p \equiv q & \text{if } x=0 \\ p & x=1 \\ 0 & \text{otherwise} \end{cases} \qquad p(x) = \begin{cases} p^x (1-p)^{1-x} & \text{if } x=0 \text{ or } 1 \\ 0 & \text{otherwise.} \end{cases}$$

$$E(X) = p, \quad Var(X) = p(1-p)$$

Binomial Distribution

$\frac{n!}{p!(1-p)!}$

$$p(x) = P(X=x) \begin{cases} \binom{n}{p} p^x (1-p)^{n-x} & \text{if } x = 0, 1, 2, \ldots, n \\ 0 & \text{elsewhere} \end{cases}$$

$$E(X) = np, \quad Var(X) = np(1-p)$$

Poisson Distribution

$$P(X=x) = \frac{e^{-\lambda} \lambda^x}{x!} \qquad x = 0, 1, 2, 3, \ldots$$

$$E(X) = Var(X) = \lambda$$

Bayes Formula

discrete random variable X

Expectation

$$E(X) = \sum x p(x) \qquad = E[X] = EX = \mu_X = \mu$$

Variance

$$Var(X) = E\left[(X-\mu)^2\right] = \sigma_X^2$$

Standard Deviation

$$= \sum (x-\mu)^2 p(x)$$

continuous random variable

Expectation

$$E(X) = \int_{-\infty}^{\infty} x f(x)\, dx$$

density function.

Variance

$$Var(X) = E\left[(X-\mu)^2\right]$$

$$= \int_{-\infty}^{\infty} (x-\mu)^2 f(x)\, dx$$

Covariance

$$\sigma_{xy} = E\left[(X-\mu_x)(Y-\mu_y)\right]$$

Correlation

$$\rho = \frac{\sigma_{xy}}{\sigma_x \sigma_y}.$$

02 Predictive Modeling

- Supervised Learning / Unsupervised Learning.
  - Supervised Learning.
    - 類似於用 y predict x ($y = \beta_0 + \beta_1 X + \epsilon$)
    - classification, regression,
    - F1, MAE (大多目前學到的統計都是)
    - Overfitting.
  - Unsupervised Learning.
    - Find patterns in X (groups, spaces)
      不用給 X output, only looking for patterns.
    - clustering, density.
    - k-means,

- Why estimate f ? → $f(x) = y$? Prediction / Inference,
- How estimate f ?

Parametric	Non-Parametric
Least Square 算出 f(x) formula	Moving Average Filter 由觀測 data 預估一個 f.
estimated $\hat{f}(x) \neq$ True model $f(x)$	① require large sets of data. ② overfitting (Train MSE 小, test MSE 大)

TRADE-OFF

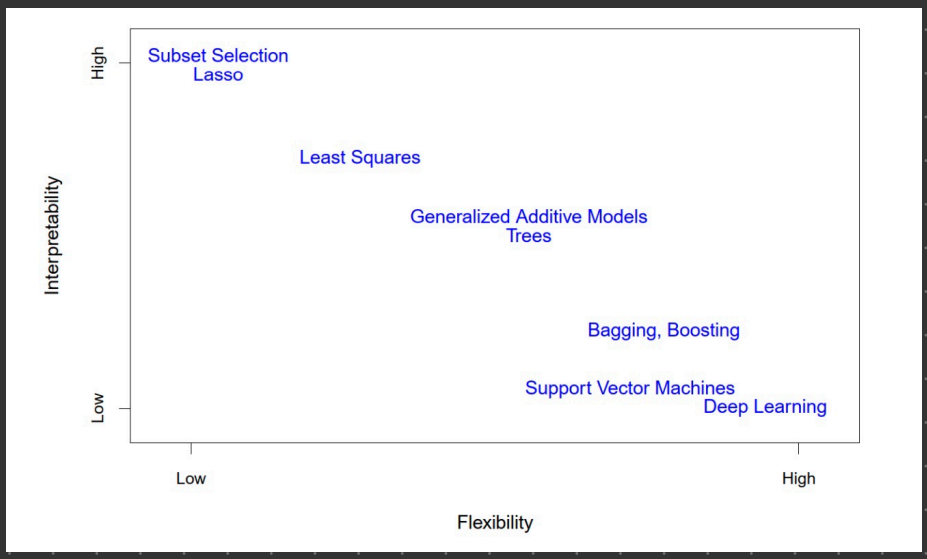

The rule of thumb

- Inference = simple / inflexible model ⇒ interpretability. 可解釋性.
- Prediction = flexible model ⇒ flexibility 彈性.

- How to choose the best f?

- Mean Square Error：量化問題

$$MSE = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{f}(x_i))^2$$

✵ Target = lowest test MSE

① IDEAL：夠多的 data 可以取平均 MSE → 夠接近 True model

$$MSE = Ave(y_0 - \hat{f}(x_0))^2$$
$$= \text{Average Square prediction Error.}$$

② Reality = low Traing MSE ≠ low test MSE ⇒ Overfitting!

Expected Test MSE = Variance of $\hat{f}(x_0)$ + the square bias + Variance of error

模型的變異程度 (flexibility) | model 與 True model 的 error | 其他因素的 error (無法 measure)

$$E(y_0 - \hat{f}(x_0))^2 = \underbrace{Var(\hat{f}(x_0)) + [Bias(f(x_0))]^2}_{\text{Reducible}} + \underbrace{Var(\varepsilon)}_{\text{Irreducible}}$$

TRADE-OFF：
- Variance = model 的變異程度
- Bias = model 與實際值的差異

FLEXIBILITY ↕ BIAS

MODEL FLEXIBILITY：
- FLEXIBLE = 高變異, 少 Bias ⇒ Overfitting! (n large / p small)
- INFLEXIBLE = 低變異, 高 Bias (p large / n small)

Rules of thumbs：
- Big n, Small p = (flex) 樣本取太多 var 高 bias 都不高
- Small n, Big P = (Inflex) 不夠準確, use regulation
- Curved = (flex) vars 很高
- Noisy Data = (Inflex) 使 Test MSE ↓

03 Linear Regression

- Linear Regression Model

slope ↑

$$y = \beta_0 + \beta_1 X + \epsilon$$

应变权 dependent = response variable

intercept

自变权 independent = regressor = predictor

Residual 残差.

$$\begin{cases} E(Y|X) = \beta_0 + \beta_1 X \\ V(Y|X) = 0 + \sigma^2 = \sigma^2 \end{cases}$$

- Least Square Method. 最小平方法.

用以计算 regression coefficients 回归係数

$\beta_0, \beta_1, \epsilon$

$$L = \sum (y_i - \beta_0 - \beta_1 x_i)^2$$

① 先算 sum of square

$$\begin{cases} S_{XX} = \sum_{i=1}^{n} (x_i - \bar{x})^2 \\ S_{XY} = \sum_{i=1}^{n} (y_i - \bar{y})(x_i - \bar{x}) \end{cases}$$

② 再算 coefficient

$$\begin{cases} \hat{\beta}_1 = \dfrac{S_{XY}}{S_{XX}} = \dfrac{Cov(X,Y)}{Var(X)} = \rho \\ \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} \end{cases}$$

$\begin{cases} \sigma & \text{母体标准差} \\ s & \text{样本标准差} \end{cases}$

- 計算 σ^2 (母体変異数)

$$\sigma^2 = \frac{SS_E}{n-p} = \frac{\text{error sum of square}}{\text{自由度}}$$

① T-distribution → 檢定母体平均是否 = μ_0

(σ unknown → S 推算，但會有不確定性，
T 檢定可補償 uncertainty)

$$T = \frac{\bar{x}-\mu}{s/\sqrt{n}} = \frac{\text{樣本 mean} - \text{母体 mean}}{\text{樣本 SD} / \sqrt{\text{樣本 number}}}$$

↓

自由度 = n-1

$Var(\bar{x}) = \frac{\sigma^2}{n}$ ⇒ $\sqrt{Var(\bar{x})} = \frac{\sigma}{\sqrt{n}}$ 同樣可得

- 算出 t 值後，確認在信賴區間內/外

Hypo { $H_0 = \mu = \mu_0$ (null) ; $H_0 = \mu \neq \mu_0$ } P (sample data / null True)

- Hypo = 檢定 β_1 β_0 是否顯著?
(在 Regression 是否 affective?)

{ H_0 $\beta_1 = \beta_{1,0}$ → 如 accept，則 $y = \beta_0$ 沒有相關性
H_1 $\beta_1 \neq \beta_{1,0}$ 通常 = 0，代表自變數與應變數無統計性關係

- T檢定 for slope (β_1)

$$T_0 = \frac{\beta_1 - \beta_{1,0}}{Se(\hat{\beta}_1)} = 0$$

- T檢定 for intercept (β_0)

$$T_0 = \frac{\beta_0 - \beta_{0,0}}{\sqrt{\sigma^2\left[\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}}\right]}}$$

⇒希望 reject H_0 = 係數不是0
= 係數有顯著性.

- mean response 平均反應
(在某個 x_0 下, 平均的 y 期望值)

- 信賴區間.

② R^2 決定係數

(用以看模型可解釋的變異比例)

$$R^2 = \frac{SS_R}{SS_T} = 1 - \frac{SS_E}{SS_T}$$

$$\begin{cases} SS_T = SS_R + SS_E \\ \text{Total} = \text{可被測} + \text{不可被測} \\ \sum (y - \bar{y})^2 = \sum (\hat{y} - \bar{y})^2 + \sum (y - \hat{y})^2 \end{cases}$$

平均值　　實際值　模型預測值

③ F - distribution

(用以解釋整體回歸的顯著性)

$$F_0 = \frac{MS_R}{MS_E} = \frac{SS_R / 1}{SS_E / n-p} = \frac{\text{估計的變異量}}{\text{另一個變異來源}}$$

σ^2

$$\begin{cases} H_1 \quad \beta_0 = \beta_1 = \beta_2 \cdots = \beta_n = 0 \\ H_0 \quad \beta_0 + \beta_1 + \beta_2 + \cdots \beta_n = 0 \end{cases}$$

⇒ 希望 Reject，代表有顯著性。

- Correlation Coefficient 相關係數
(兩變數之間的線性關係)

$$Cor(x,y) = \rho = \frac{\sigma_{xy}}{\sigma_x \sigma_y} = \frac{Cov(x,y)}{\sqrt{Var(x)\,Var(y)}}$$

$$\begin{cases} \beta_0 = \mu_y - \mu_x \rho \frac{\sigma_x}{\sigma_y} = \bar{y} - \bar{x}\hat{\beta}_1 \\ \beta_1 = \frac{\sigma_y}{\sigma_x}\rho = \frac{Cov(x,y)}{Var(x)} = \frac{\sigma_{xy}}{\sigma_x^2} \end{cases}$$

04 Multiple Linear Regression 複迴歸

Full Model $y=\beta_0+\beta_1X_1+\beta_2X_2+\beta_3X_3+\cdots+\beta_KX_K+\varepsilon$

可簡化 $Y=X\beta+\varepsilon$ (皆代表矩陣)

Least Square Method Residual = observation − fitted value

目標：使殘差平方和最小

(ε 的自然定義是屬於 y)

$$\min L(\beta)=\sum\varepsilon^2=\varepsilon'\varepsilon=(y-X\beta)'(y-X\beta)$$

$$\hat{\beta}=(X'X)^{-1}X'y$$

可用此 β 找到最小的 ε

σ^2 $\sigma^2=\dfrac{\sum\varepsilon_i^2}{n-p}=\dfrac{SS_E}{n-p}=MS_E$

F-tests

$$\begin{cases} H_0: \beta_1=\cdots=\beta_K=0 \\ H_1: \beta_1,\ldots\beta_K \text{ at least one} \neq 0 \end{cases}$$

$$F_0=\frac{MS_R}{MS_E}=\frac{SS_R/k}{SS_E/(n-p)}$$

k: df of regression.

$(n-p)$: df of error

Source of Variation	Sum of Squares	Degrees of Freedom	Mean Square	F_0
Regression	SS_R	k	MS_R	MS_R/MS_E
Error or residual	SS_E	$n-p$	MS_E	$p=k+1$
Total	SS_T	$n-1$		p是predictor的數量

$$\begin{cases} SS_R = \hat{\beta}'X'y - \dfrac{(\sum y_i)^2}{n} \\ SS_E = SS_T - SS_R \\ SS_T = y'y - \dfrac{(\sum y_i)^2}{n} \end{cases}$$

Coefficients

Full Model $\begin{cases} E(\hat{\beta}) = \beta \\ Cov = (X'X)^{-1} \end{cases}$

Individual Coefficients $\begin{cases} Var(\hat{\beta}_j) = \sigma^2 c_{jj} \\ Cov(\hat{\beta}_i, \hat{\beta}_j) = \sigma^2 c_{ij} \quad i \neq j \end{cases}$

T-tests

partial / marginal test 偏回歸

(其他變數不變之下, x_i 是否對 y 仍有貢獻?)

$$\begin{cases} H_0 = \beta_j = \beta_{j0} \\ H_1 = \beta_j \neq \beta_{j0} \end{cases} \qquad T_0 = \frac{\hat{\beta}_j - \beta_{j0}}{\sqrt{\sigma^2 c_{jj}}} = \frac{\hat{\beta}_j - \hat{\beta}_{j0}}{se(\hat{\beta}_j)}$$

$$\begin{cases} \text{單一樣本 } t \quad t = \dfrac{\bar{x} - \mu}{s/\sqrt{n}} \Rightarrow \text{看母體平均} = \mu_0 ? \\ \text{迴歸係數 } t \quad t = \dfrac{\beta_j - \beta_{j0}}{Se(\beta)} \Rightarrow \text{看 } x_j \text{ 是否對 } y \text{ 有貢獻?} \end{cases}$$

Confidence Interval

$$\hat{\beta}_j - t_{\alpha/2,n-p}\sqrt{\hat{\sigma}^2 C_{jj}} \le \beta_j \le \hat{\beta}_j + t_{\alpha/2,n-p}\sqrt{\hat{\sigma}^2 C_{jj}}$$

Mean Response

mean = $\hat{\mu}_{Y|x_0} = x_0'\hat{\beta}$

Variance = $Var(\hat{\mu}_{Y|x_0}) = \sigma^2 x_0'(X'X)^{-1}x_0$

CI on Prediction

觀測噪音 → 區間更寬

$$\hat{y}_0 - t_{\alpha/2,n-p}\sqrt{\hat{\sigma}^2(1 + x_0'(X'X)^{-1}x_0)} \le Y_0 \le \hat{y}_0 + t_{\alpha/2,n-p}\sqrt{\hat{\sigma}^2(1 + x_0'(X'X)^{-1}x_0)}$$

Model Adequacy Check

① **Adjusted R^2**

$R^2 = \frac{SS_R}{SS_T}$ 當加入"無關"的新資料，p個自由度↓

SS_E不變or↓(不可解釋部份沒有差異，df↓ n-p個)

SS_E↓ SS_T不變 R^2↑

引入R_{adj}^2，有Penalties避免此情況，

$$R_{adj}^2 = 1 - \frac{SS_E/(n-p)}{SS_T/(n-1)}$$

p↑ 自由度↓ SS_E↑ $\frac{SS_E}{SS_T}$↑ R^2↓

(加入新的predictor不一定有讓R^2↑，避免overfitting)

② **Residual Analysis**

R^2很高的情況下，

可能形狀或變數仍不對(加變數 etc)

→ 用Residual Analysis觀察ε

1 Normal Distribution plot 常態机率图 (QQ plot)

IDEAL 残差近似常態 (大致沿直線)

2 Standardized Residual 標準化殘差

$$d = \frac{\varepsilon_i}{\sqrt{MSE}} = \frac{\varepsilon_i}{\sqrt{\sigma^2}} \quad (|d|>3 \text{ 才須要注意})$$

IDEAL $|d| \le 3$ 標準化後取值不分散.

3 Scatter Plot (Residual vis. $\hat{y}/x_j$)

IDEAL ε 分布像噪音

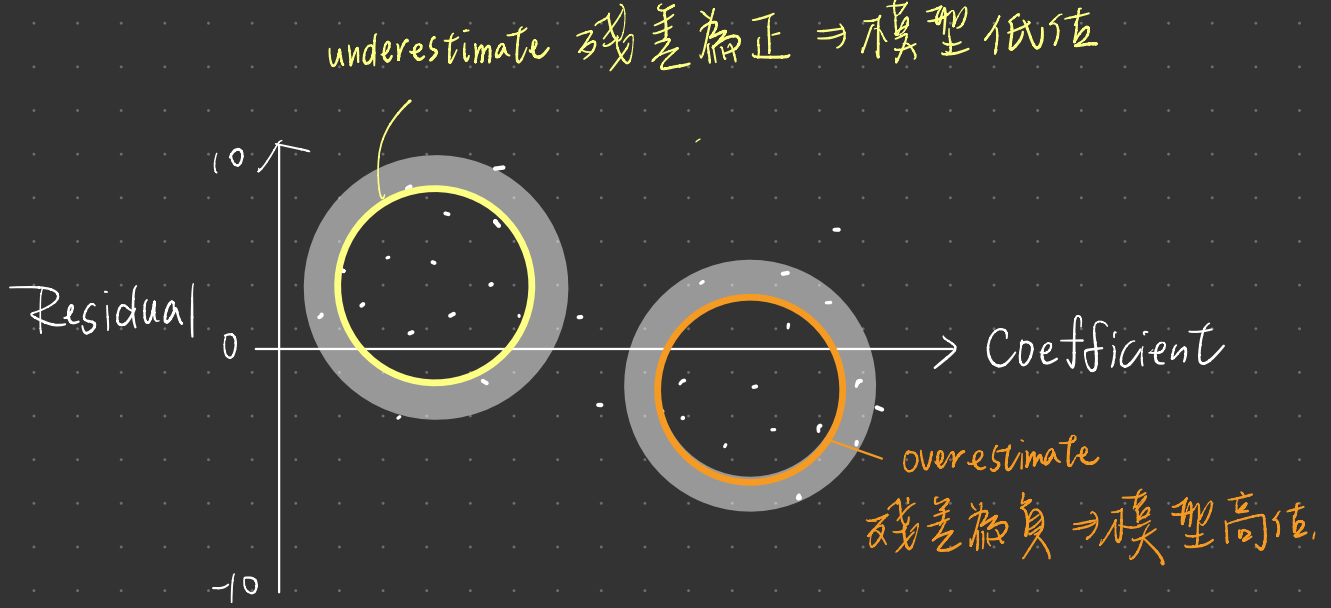

用形狀看修正
- U型 ⇒ 加二次項
- 漏斗型 ⇒ 可能異方差
- 曲線 ⇒ 非線性或遺漏變數.

Other Consideration

1. Interaction

hierarchy principle：有交互作用的子效應/主效應都保留，
（即便p-value高，因為難以估影響交互的範圍）

2. Polynomial Regression Model

多項式，也可能有多次方，（仍是linear Regression）

3. Categorical Predictor

= dummy variable = indicator variable

Selection of Variables

1. extra sum of square / partial - F

$$F = \frac{SS_R(\beta_1 \mid \beta_2)/r}{MS_E} \qquad SS_R(\beta_1+\beta_2) - SS_R(\beta_2)$$

$$= \frac{SS_R \text{ reduced} - SS_R \text{ full}}{SS_E \text{ full} / (n-p)}$$

Partial-F $\begin{cases} H_0: \beta_1 = 0 \Rightarrow$ 係數不重要，可刪
$H_1: \beta_1 \neq 0$ Reject H_0 = 係數有顯著性

Model Adequacy ① F-test / P-value / T-test / R^2

② R^2 很高的情況下 → Residual Analysis

→ 確定 model 的變數（形狀）是否須修正

③ 須確認各predictor的顯著性，

→ Partial F / extra sum of square

④ 重新檢查 R_{adj}^2 → 須有所上升!

2 Akaike Information Criterion (AIC)

$$AIC = -2\ln(L) + 2p$$

L: Likelihood; p: parameter

$$= 2p + n\ln(MSE) + C$$

C ≡ constant

IDEAL: lower → better fit

($\Delta AIC = -2$ significantly better)

3 Bayesian Information Criterion (BIC)

$$BIC = -2\ln(L) + p\ln(n)$$

n: sample size

penalty term = 減少 overfitting 可能.

IDEAL: lower → better fit

preferred with simple model

4 Cp statistic

套入不同的 p.

$$Cp = \frac{SSE(p)}{\sigma_{full}^2} - n + 2p$$

IDEAL: Cp closest to P.

5 Cross-validation (CV)

$$PRESS = \sum(y_i - y_{(i)})^2 = \sum\left(\frac{\varepsilon}{1-h_{ii}}\right)^2$$

h_{ii}: hat matrix

6 Forward / Backward Selection

Forward: 0% 開始, 每次加最有用的變數.

Backward: 100% 開始, 每次拿最(p-value)無用的變數.

Multicollinearity 多重共線性

$$VIF(\beta) = \frac{1}{(1 - R_j^2)}$$

- Multicollinearity：自變數彼此相關（資訊重疊）
  - 看VIF.（F sign yet t not sign）
- Interaction：x_1對y有受到x_2對y的影響（資訊無重疊）
  - 看x_1x_2項的p-value，R^2提升？

05 classification I

痛点：Linear Regression y_i 有超過 0-1 → 無法解釋机率的問題

Logistic Regression

限制 0-1 之間

$$\log\left(\frac{p_i}{1-p_i}\right) = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \beta_3 x_{i3} + \cdots \beta_p x_{ip}$$

log-odds 對数勝算

Y=1 與 Y=0 的比率對数

$$p_i = \frac{e^{\beta_0 + \beta_1 x_1 + \cdots \beta_p x_{ip}}}{1 + e^{\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots}}$$

Maximum Likelihood Function ⟷ 相對於 Linear 的最小平方法

用以計算 β ⇒ 算出最大值 → 机率最大、最有可能

Likelihood $L(\beta_0 \cdots \beta_p) = \prod p^y (1-p)^y = \prod (1-p)\left(\frac{p}{1-p}\right)^y$

（所有机率乘積）

↓ 取 log 方便運算

log-Likelihood

$$l(\beta_0, \cdots, \beta_p) = \sum_{i=1}^{n}\left(Y_i \log\left(\frac{p_i}{1-p_i}\right) + \log(1-p_i)\right)$$

$$= \sum_{i=1}^{n}\left(Y_i \sum_{j=0}^{p} \beta_j x_{ij} - \log\left(1 + e^{\sum_{j=0}^{p} \beta_j x_{ij}}\right)\right)$$

求最大值

Newton Raphson

$$\hat{\beta}_{n+1} = \hat{\beta}_n - \frac{l'(\hat{\beta})}{l''(\hat{\beta})}$$

一階導 / 二階導

① 隨机選 β_n

② 代入 $l'(\beta)$, $l''(\beta)$ 算出 β_{n+1}

③ 重複 ①+② 直到 β_{n+1} 不變化

Likelihood Ratio Test

模型的估計

$$D = -2(\log L_{reduced} - \log L_{full})$$

$$= -2\log \frac{L(\beta_0 \sim \beta_{p-1})}{L(\beta_0 \cdots \beta_p)} \longleftarrow \text{少了 } \beta_p$$

chi-square

$D > \chi^2$ 時 拒絕 H_0，該變數顯著

Binomial Logistic Regression

{ Bernoulli：單次實驗成功/失敗的機率
Binomial：多次實驗的成功/失敗總類

從觀察個體變為彙總的形式

觀察次數

$$Pr(Y) = \binom{n_i}{y_i} p_i^{y_i} (1-p)^{n_i - y_i}$$

n次中成功x次

$$L(\beta_0, \cdots, \beta_p) = \prod_{i=1}^{N} \frac{n_i!}{y_i!(n_i - y_i)!} p_i^{y_i} (1-p_i)^{n_i - y_i} = \prod_{i=1}^{N} (1-p_i)^{n_i} \left(\frac{p_i}{1-p_i}\right)^{y_i}$$

LR計算的

$$l(\beta_0, \cdots, \beta_p) = \sum_{i=1}^{N} \left(y_i \log\left(\frac{p_i}{1-p_i}\right) + n_i \log(1-p_i) \right)$$

$$= \sum_{i=1}^{N} \left(y_i \sum_{j=0}^{p} \beta_j x_{ij} - n_i \log\left(1 + e^{\sum_{j=0}^{P} \beta_j x_{ij}}\right) \right)$$

Multinomial Logistic Regression

Y=1 or 0 兩類 ⇒ Y有K個類別

Solution 1 : Baseline

選定其中一類(Y=第K類)作為Baseline (One v.s. Rest)

$$\log\frac{\Pr(Y_i=k\mid X=x_{i1},\cdots x_{ip})}{\Pr(Y_i=K\mid X=x_{i1},\cdots x_{ip})}=\beta_{k0}+\beta_{k1}x_{i1}+\cdots+\beta_{kp}x_{ip}$$

和率形式表達

對 k=1,..., K-1

$$\Pr(Y_i=k\mid X=x_{i1},\cdots x_{ip})=p_i=\frac{e^{\beta_{k0}+\beta_{k1}x_{i1}+\cdots+\beta_{kp}x_{ip}}}{\sum_{l=1}^{K}e^{\beta_{l0}+\beta_{l1}x_{i1}+\cdots+\beta_{lp}x_{ip}}}$$

對 K (Baseline)

$$\Pr(Y_i=K\mid X=x_{i1},\cdots x_{ip})=\frac{1}{1+\sum_{l=1}^{K-1}e^{\beta_{l0}+\beta_{l1}x_{i1}+\cdots+\beta_{lp}x_{ip}}}$$

Solution 2 : Softmax

不指定基準，每類都有自己的線性分配函(X)

h^{th} - k^{th} 之間的log-odds

$$\log\frac{\Pr(Y_i=h\mid X=x_{i1},\cdots x_{ip})}{\Pr(Y_i=k\mid X=x_{i1},\cdots x_{ip})}=(\beta_{h0}-\beta_{k0})+(\beta_{h1}-\beta_{k1})x_{i1}+\cdots+(\beta_{hp}-\beta_{kp})x_{ip}$$

06 classification II

	Logistic Regression	Linear Discriminant Analysis.
	input X → output y 給X，判定y的類別 Discriminant model	input y → output X 給y的類別，判定X的分布 Generative model
	只畫分界線，不管形狀	先了解每個類別分布的形狀 再畫分界線
類別分很開 ⇒	係數會變很大 (β_i, Var) 不穩定	平均差很大，交變異數正常 係數穩定 ☑
n小 ⇒	只憑過異， sample小容易不穩定	有assume"每一類X分布都differ這常態"用少sample可以抓形狀， Variance小
	有事實 $P(Y\|X)$	先算 $P(X\|Y)$ 再用Bayes倒回 $P(Y\|X)$

Discriminant Analysis 區隔分析

用Bayes theory回推？$P(Y|X)$

$$P_K(X) = \frac{\pi_K f_K(X)}{\sum \pi_i f_i(X)}$$

- $P_K(X)$：Posterior Probability，後驗機率
  - 觀測到X後，樣本屬於第K類的"更對"機率
- π_K：Prior Probability，先驗機率
  - 觀察到任何特徵前隨機抽到第K類的機率
- $f_K(X)$：density function，密度函數/似然
  - 在第K類成立的條件下，觀察到X的機率是多少，aka若屬於K類，X有多合理，分散越大，不越常見
- 分母：各類機率加總（正規化）

Linear Discriminant Analysis

$f_k(x)$ 代入 Bayes 後得為 Full Model

假設 $\sigma_1^2 = \sigma_2^2 = \cdots = \sigma_K^2 = \sigma^2$

$$p_k(x) = \frac{\pi_k \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{1}{2\sigma^2}(x-\mu_k)^2\right)}{\sum_{l=1}^{K} \pi_l \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{1}{2\sigma^2}(x-\mu_l)^2\right)}$$

($f_k(x)$)

Discriminant Function 判別函數

- 由 Full model take a log
- $\delta(x)$ 最大時，x 屬於該類別

P=1

estimated mean $= \frac{1}{n_k} \sum_{y=k} x_i$

estimated P $= \frac{n_k}{n}$

$$\delta_k(x) = x \cdot \frac{\mu_k}{\sigma^2} - \frac{\mu_k^2}{2\sigma^2} + \log(\pi_k)$$

① 是 x 的線性函數

② 共用 SD

estimated variance $= \sum_{k=1}^{K} \frac{n_k - 1}{n - K} \cdot \sigma_k^2$

假設相等

P>1

$$\delta_k(x) = x^T \Sigma^{-1} \mu_k - \frac{1}{2} \mu_k^T \Sigma^{-1} \mu_k + \log \pi_k$$

covariance matrix 協方差

① 也是 x 的線性函數

② 共用 covariance matrix

③ predictor = one-dimension 常態分布

- LDA P>1 → 共用 cov
- MDA → 各自有 cov

DA的使用方法

① 先算每一類別的 $\hat{\delta}_k(x)$
- 用data算出 μ_k, π_k, Σ，帶入 δ（此時只是分數）

② 分數變機率（正規化）
- 分數取指數(e)，成比例化
  ↳ 轉成 0-1 的機率

最大的 $\delta_k(x)$，Pr 最大
⇒被classify到那組

$$Pr(Y=k, X=x) = \frac{e^{\hat{\delta}_k(x)}}{\sum_{i=1}^{k} e^{\hat{\delta}_i(x)}}$$

Confusion Matrix 混淆矩陣

評估模型的好壞：missclassification rate

		TRUE	
		POSITIVE	NEGATIVE
PREDICT	POSITIVE	Sensitivity	False Positive
	NEGATIVE	False Negative	Specificity

* Trade off：ex：Reduce threshold
  （Sensitivity ↑ 抓到更多這病的人
  Specificity ↓ 誤判更多正常人

* ROC Curve
(Reciever Operating Characteristic)

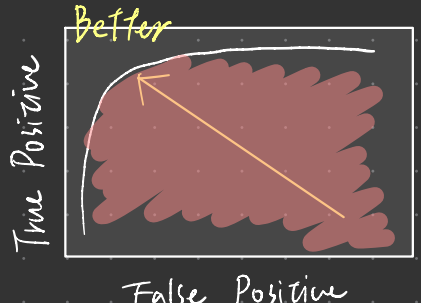

曲線越靠左上角越好 ↖

AUC（曲線下的面積）：衡量模型表現

Quadratic Discriminant Analysis (QDA)

和LDA相同，只是① 有二次項（平方項/交互項）

② 每類別有自己的 Σ_k（cov矩陣）

↓ 在 $y=k$ 時，各 x 有自己的形狀

$$\begin{aligned}\delta_k(x) &= -\frac{1}{2}(x-\mu_k)^T\Sigma_k^{-1}(x-\mu_k) - \frac{1}{2}\log|\Sigma_k| + \log\pi_k \\ &= -\frac{1}{2}x^T\Sigma_k^{-1}x + x^T\Sigma_k^{-1}\mu_k - \frac{1}{2}\mu_k^T\Sigma_k^{-1}\mu_k - \frac{1}{2}\log|\Sigma_k| + \log\pi_k\end{aligned}$$

x^2 項 → 曲線！

算法：同樣算出 μ_k, π_k, Σ_k

* 與 LDA 的比較 ⇒ 一種 Trade off：用高變異換可能有大偏差

假設 p 個 predictor → 總共要估 p×p 個 cov 矩陣 →

→ 須要 $p(p+1)/2$ 個參數 → 每一朵雲（類別）形狀不同 →

→ QDA 要考慮的更多、更靈活，同時變異更大

選 LDA / QDA？

※ $\Sigma_1=\Sigma_2$ 真實這樣 ⇒ LDA（吻合LDA假設）

$\Sigma_1\neq\Sigma_2$ ⇒ QDA

※ 樣本數少 → LDA（有假設sample是常態分布）

樣本數多，且形狀不明類時 → QDA（trade off 問題不大）

Naive Bayes

假設同一類別中（$y=k^{th}$ class），各特徵（predictors）互相獨立（cov不吃資料量）

$$f_k(x) = f_{k1}(x_1) \cdot f_{k2}(x_2) \cdot f_{k3}(x_3) \cdots f_{kp}(x_p)$$

（獨立條件發生時，p = 條件連乘）

$f_k(x)$ 代入 $p_k(x)$ 得

$$\Pr(Y=k|X=x) = \frac{\pi_k \times f_{k1}(x_1) \times f_{k2}(x_2) \times \cdots \times f_{kp}(x_p)}{\sum_{l=1}^{K} \pi_l \times f_{l1}(x_1) \times f_{l2}(x_2) \times \cdots \times f_{lp}(x_p)}$$

使用：適合 p 大 n 小（因為假設強）

大幅降低變異（有用一點偏差 trade off）

Estimate $f_k(x)$ 的方法

3) 單變量密度要怎麼估？（每個特徵各估一個 f_{kj}）

- **數值型**：假設高斯 $X_j \mid Y = k \sim \mathcal{N}(\mu_{jk}, \sigma^2_{jk})$。 2e5ccb7e-7589-44a2-8a42-7ad896e...
- **非參數**：用**直方圖**或**核密度**（平滑的直方圖）。 2e5ccb7e-7589-44a2-8a42-7ad896e...
- **類別型**：直接數比例（每個類別下，各種類別值的機率）。 2e5ccb7e-7589-44a2-8a42-7ad896e...

> 小補充：**Gaussian Naive Bayes** 等價於假設每一類的協方差矩陣是**對角**（特徵獨立），而且 NB 可以**混合**數值與類別特徵一起用。 2e5ccb7e-7589-44a2-8a42-7ad896e...

Poisson Regression Model

計數用 優點 → ① 避免預測出負值 β.

② 計數資料的特性"平均越大，變異越大"

$\Rightarrow E(Y) = Var(Y) = \lambda$.

③ $y=0$ 時不能取 log.

$\lambda = E(Y) = Var(Y)$ 給定 x 後，Y 的期望值

$$P(Y=k) = \frac{e^{-\lambda}\lambda^{k}}{k!} \quad \text{for } k = 0, 1, 2, \dots$$

Estimate λ 取 log

$$\log \lambda = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \dots \beta_p X_p$$

$$\lambda = e^{\beta_0 + \beta_1 X_1 \dots \beta_p X_p}$$

X_j 每增加 1，$E(Y) \times e^{\beta_j}$ (倍率增長)

Generalized Linear Model

統一不同 Regression Model 的框架.

① 假設 $x_1, \dots, x_p$, Y 屬於其中一種分布.

- Linear regression - Y follows a Gaussian or normal distribution.
- Logistic regression - Y follows a Bernoulli distribution
- Poisson regression - Y follows a Poisson distribution

② Link Function 連結函數 η

變換後的平均等於線性組合.

$$\eta(\mathrm{E}(Y|X_1,\dots,X_p)) = \beta_0 + \beta_1 X_1 + \cdots + \beta_p X_p$$

$$\begin{cases} \text{Linear} = \eta(\mu) = \mu \\ \text{Logistic} = \eta(\mu) = \log \dfrac{\mu}{1-\mu} \\ \text{Poisson} = \eta(\mu) = \log \mu \end{cases}$$

K Nearest Neighbors

3-10 prefered.
odd number better

new input x → 找離 x 最近的 K 個資.

→ assign 給 K 中最多的類別.

↕

Regression = 取 K 個資的平均值做模測.

使用時机 = Bounday 不規則. → 決策邊界 free

Data 小, 特徵少.

叁 Tree-Based Method

- 可用在 regression / classification 的問題
- [useful for interpretation ↔ trade-in.
  [not the best in prediction accuracy.

Quinlan Algorithm

- Main Concept: Entropy and Information Gain.
- 不考慮 dependency (已包括於假設).

① Step 1 = 計算 response variable 的 Entropy.

Entropy = 用於計算 sample 的同質性 (homogeneity)
(越純 → 接近 0，平均 divided → 接近 1)

$$Entropy(S) = \sum_{i=1}^{n} -p_i \log_2 p$$

② Step 2 = 計算 weighted entropy (逐一)

$$\text{Weighted Entropy}(T, X) = \sum p(c)\, E(c)$$

$p(c)$: entropy of response variable
(T, X): (response, predictor)
$E(c)$: 此類別化后的 entropy.

③ Step 3 = 決定架構

計算 Information Gain (逐一)
挑選出最大的作為 decision tree 的架構.

IG = Entropy 熵 − Weighted Entropy 加權熵.

④ Step 4：往下畫分支

T(s) = 0，則停止，否則無限分支。

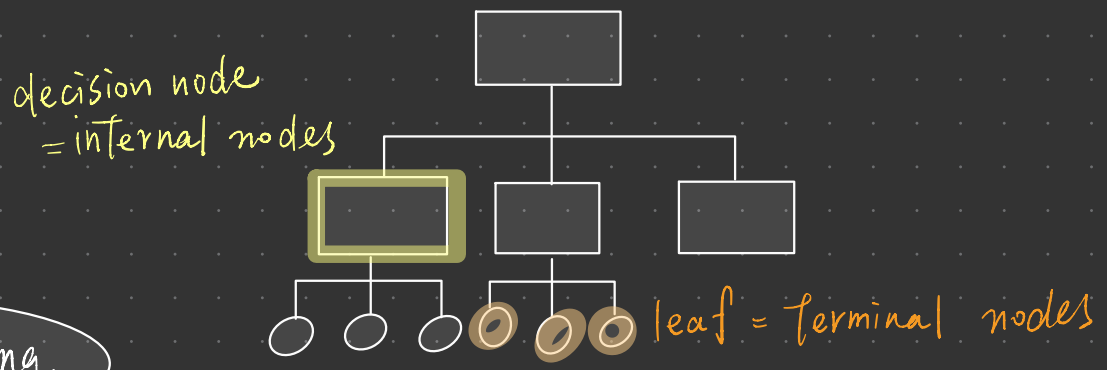

Tree Building

- 分割成 J 個區域，以平均值作為預測值。
- Goal：Minimize RSS (Residual sum of square)
  → minimize / reduce total variation

response variable / observed points.

$$RSS = \sum_{j=1}^{J} \sum_{i \in R_j} (y_i - \hat{y}_{R_j})^2$$

mean response

make a group as homogeneous as possible.

- How：Recursive Binary Splitting
  - top-down：從樹的頭開始 split.
  - greedy：每次分裂只看當下 min RSS 做選擇。

① 將資料切開成 R_1, R_2，使 RSS 降幅最大。

$$\begin{cases} R_1(j,s) = \{X \mid X_j < s\} \\ R_2(j,s) = \{X \mid X_j > s\} \end{cases}$$

找最小的 (j,s) minimize $\sum (y_i - \hat{y}_{R_1})^2 + \sum (y_i - \hat{y}_{R_2})^2$

mean response.

② 重複在現有區域劃分。

- Prune 修剪

- Method 1: 每次都需降幅超過指定門檻.
  → 可能會誤刪前面小、後面大的路.

- Method 2: 直接長一棵很大的樹、再修剪.
  → 類似 Backward Selection.

- How: select subtree leads to lowest test error.
  平衡"複雜度"和"fitting"

Cost Complexity / Weak link pruning

$$\text{Cost}(T) = \sum_{m=1}^{|T|} \sum_{x \in R_m} (y_i - \hat{y}_{Rm})^2 + \alpha |T|$$

size of the tree

$\sum_{m=1}^{|T|} \sum_{x \in R_m} (y_i - \hat{y}_{Rm})^2$: Training RSS. 各 Terminal node 的 SSE ≒ fit 的品質.

$\alpha |T|$: penalty term 樹的複雜度成本.

α 複雜度懲罰係數
- $\alpha = 0$ 原始大樹是最佳.
- α 越大, 偏好越小子樹

↳ How to choose?

K-fold cross validation. min

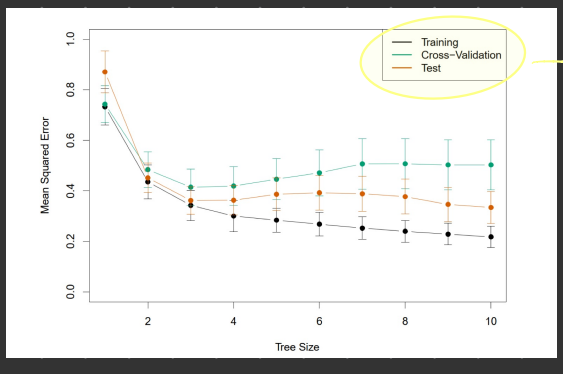

Train MSE: 下降, 但過低是 overfit

CV MSE: 用來選最佳模型.

Test MSE: 最終評估, 但不能用來做選擇.

Classification Tree

項目	Regression Tree	Classification Tree
預測对象	數值 (定量 Y)	類別 (定性 Y)
Terminal node prediction	節點內 平均值	節點內 最多數類別
Split criterion	最小化 RSS	最大化純度 (Gini/Entropy)

① Classification error rate = 用於 Tree Building.

$$E = 1 - \max_k (\hat{P}_{mk})$$

在 m^{th} region 中屬於 k^{th} class 的 比例

缺失：不變動不敏感 ↓

② Gini Index / Cross Entrophy ⇒ Max

⇒ 2者皆取值越小越好

① Gini Index = Total variance across K class.

mis-classification

$$G = \sum_{k=1}^{K} \hat{P}_{mk}(1 - \hat{P}_{mk})$$

weight

- G=0 = 純度高 (node purity)，節点N手屬於同一類.
- G越大 = 越混亂

② Cross-Entrophy.

$$D = -\sum_{k=1}^{K} \hat{P}_{mk} \log \hat{P}_{mk}.$$

$\hat{P}_{mk}$ 接近 0 or 1 則 D 接近 0

純度高時，D (Entrophy) 會很小.

📊 Regression Tree vs Classification Tree — Advantages & Disadvantages

面向	Regression Tree	Classification Tree
用途	預測連續數值（e.g. salary）	預測類別（e.g. heart disease Yes/No）
解釋性	高 — 可視化規則、可解釋區間	高 — 路徑條件直覺、易傳達
處理類別變數	可處理（自動做 split）	天然適合，類別共現更直觀
建模過程	以最小化 RSS 作為 split 依據	以最大化 node purity (Gini/Entropy) 作為 split 依據
優點	- 規則可視化、決策透明 - 不需假設線性關係 - 可自動處理 interaction	- 較符合人類決策直覺 - 直接輸出類別與信心比例 - 同樣避免線性假設與 dummy 編碼
缺點	- 易 overfit → test error 較差 - 對資料小變動敏感（不穩定）	- 單一樹準確率偏低 - 同樣存在 high variance 問題
改善策略	Bagging / Random Forest / Boosting	Bagging / Random Forest / Boosting

8 Tree Based Method II

- simple decision tree 缺点: high variance.

Ensemble Method 透過許多的樹集合 ⇒ 解決 high variance.

① Bagging.

- = Bootstrap aggregation
- 先建很多棵, 再平均 → 使預測穩定.
  (Bootstrap抽樣放回)

產成 B 組 training set

- Regression

$$\hat{f}_{bag}(x) = \frac{1}{B}\sum_{b=1}^{B}\hat{f}^{*b}(x)$$

每 $\hat{f}(x)$ high var/low bias ⇒ 平均後消除 high var.

- Classification

取 B 棵樹的投票結果 ⇒ 出現最多的類別 = Prediction.
以多表 (majority vote) 取結果.

- Out-of-Bag error estimation (OOB)
  用以估計 bagged model 的 Test error.

- 每建一棵樹, data
  - 2/3 build tree.
  - 1/3 ⇒ 預測每一次的 test error.
    ⇒ 累積 B 次.
    ⇒ 平均後 OOB Test error

OOB.

- Variable Importance.
  - Regression = 累積平均 RSS reduction amount.
  - Classification = 累積平均 Gini reduction amount.

⇒ 值越大 (下降越多) 越重要.

Bagging 缺點：某一 predictor 太強 ⇒ 不同的樹 high related

⇒ 降 var 的效果有限

② Random Forest

- 用 decorrelate（去相關化）解決 Bagging 的問題
- 每次 split 隨機抽 m 個 predictor（$m \approx \sqrt{p}$）⇒ 更穩定
  （⟷ bagging 每次都考慮全部 p）
- 若 predictor 高度相關 ⇒ 取小一點的 m（可以減少主導性）

③ Boosting

Boosting 與 bagging/RF 最大不同：

方法	grow 樹方式	是否互相獨立
Bagging / RF	同時並行	樹與樹互不影響
Boosting	**序列式逐棵生長**	**每一棵依賴上一棵的殘差**

用上一階段的殘差訓練新的小樹

$$f(x) = f(x) + \lambda \cdot Tree_b(x)$$

data { 共 B 組
每組有 1 個 λ

λ：學較慢但較穩健

① 先算 $f^b(x)$（用當次 training set）

② 更新 $f(x)$：新 $f(x)$ ← 原 $f(x) + \lambda f^b(x)$

③ 算殘差：$r_b = f^b(x) - f^{b-1}(x)$

④ 更新殘差：新 r ← 原 $r - \lambda f^b(x)$

⑤ 新預測 = old model + $\lambda \times f^b(x)$

重複 B 次

太大會 overfit

用 cross validation 選

9 Resampling Method ⇒ estimate test error

Validation Set Approach

- Training set : fit model
- Validation set (hold-out set)
  - Regression ⇒ 計算 MSE
  - Classification ⇒ 計算 misclassification

缺① test error var 高!
隨机切分的变異太大.
② Overestimate (高估) test error
樣本数又更少, test MSE 偏大.

可解決

↓ cross-validation.

Leave One Out Cross-Validation = LOOCV

n 筆 data
- Training set : n-1
- Validation set = 1

⇒ test MSE = n 次 MSE 的平均

$$CV_{(n)} = \frac{1}{n}\sum MSE$$

優① 偏差小
② no randomness
③ 最小平方法 (OLS) 有捷徑公式 → $CV_{(n)} = \sum_{i=1}^{n}\left(\frac{y_i - \hat{y}_i}{1-h_{ii}}\right)^2$

$\hat{y}_i$: full model 在 i^{th} fitted 的
h_{ii}

和 K-fold 相對.
每次分組前有打亂数據.
每一筆被分到 training / valid set 次数不同.

K-fold Cross Validation

k sets of data
- Training set = k-1
- Validation set = 1

⇒ test MSE = k 次 MSE 的平均

$$CV_{(k)} = \frac{1}{k}\sum_{i=1}^{k} MSE_i$$

優① 便宜 ② 通用.

CV

缺 flexibility高 ⇒ 高估, 低估 True MSE

CV的 Two Goals
- 預估 True test MSE
  - 看模型的準確度
- 選擇模型
  - 只能比較MSE的大小, 無法看絕對大小

Trade off

Bias / Var	LOOCV	k-fold
Bias	👑 幾乎沒有偏差 (n-1筆來train)	k=5 or 10 略大
Variance	資料高度相關 Var高	👑 Var有低

- k越大: Bias低, Var高
- k越小: 高, 低 (flexible)

Bootstrap

→ 從n筆data中, 抽B次, 每次放回,
以每次抽樣結果集合成新的 data set.

10 Dimension Reduction

- eigenvalue 特徵值
- eigenvector 特徵向量

- Orthogonal (a,) 內積 = 0
- orthonormal (a,) 內積 = 0, unit vector

Principle Components Analysis

- 把資料轉到新的座標軸上. (eigenvector)
  用 PC1, PC2 ..... 代表原始資訊.
- ① 新變數 (PC scores) 互相獨立
  eigenvectors are orthogonal.
  ② PC1, PC2, ... 含由大到小解釋變異的多寡.
  ③ PC 是原變數的線性組合, $z = \Sigma \phi x = \phi_1 x_1 + \phi_2 x_2 + \cdots$

Spectral Decomposition 譜分解.

Σ 矩陣 = 特徵值 λ × 特徵向量 V

covariance matrix 共變異矩陣

$$\Sigma = (X-\mu)^T (X-\mu)$$ p.9.

$$= PDP^T$$

$$= [v_1, v_2, \ldots, v_n] \begin{bmatrix} \lambda_1 & & 0 \\ & \lambda_2 & \\ & & \ddots \\ 0 & & \lambda_n \end{bmatrix} \begin{bmatrix} v_1 \\ v_2 \\ \vdots \\ v_n \end{bmatrix}$$

- 資料中心化後
  矩陣 X 的變異
  存在變異矩陣 Σ
  $\Sigma = X^T X$

λ_n 皆為 eigenvalue, 代表變化的量
$\lambda_1 > \lambda_2 > \lambda_3 \ldots$

v_n 皆為 orthonormal eigenvector
代表主要的方向

✡ PCA = 共變異矩陣的 eigen decomposition

↓

{ eigenvalue 變異的大小
  eigenvector 資料分佈、變異的方向 (內在結構)

original data 矩陣

PC score = new data

$$Y = (X - \mu) P$$

$P = [\, v_1\ v_2\ \cdots\ v_n \,]$ eigenvector

Singular Value Decomposition 奇異值分解

可使用於不是對角矩陣的

X = 映射資料點的位置 × 伸縮的值 × 伸縮的方向

$$X = U \cdot A \cdot V^T = U \cdot D \cdot P$$

$(m \times n)$ $(m \times m)$ $(m \times n)$ $(n \times n)$

eigenvector ↑

$$= \begin{bmatrix} \uparrow & \uparrow & & \uparrow \\ u_1 & u_2 & \cdots & u_n \\ \downarrow & \downarrow & & \downarrow \end{bmatrix} \begin{bmatrix} \sqrt{\lambda_1} & & & 0 \\ & \sqrt{\lambda_2} & & \\ & & \ddots & \\ 0 & & & \sqrt{\lambda_n} \end{bmatrix} \begin{bmatrix} \leftarrow v_1 \rightarrow \\ \leftarrow v_2 \rightarrow \\ \vdots \\ \leftarrow v_n \rightarrow \end{bmatrix}$$

↓ PC scores 的方向

↓

singular value $= \sqrt{\text{eigenvalue}}$

($X = UAV^T$ 代入 Y)

$$Y = XV = UA$$

PC score

↘ 👑

{ ① 不用算 $\Sigma = X^T X$
  ② 直接 X 做 SVD
  ③ XV 得到 Y

$Var(Y) = D$ 每個 PC 的 variance = 對應的 eigenvalue

- PCA的主要使用

① Dimension Reduction
原始data高度相關，資訊重疊
可透過PCA取出前k個PC代表大部分變異

② 下游分析的前處理
確保PC之間是獨立，避免 overfitting / multicollinearity.

- Variance的變化

- Total variation of X $= \sum Var(Y)$
$= trace(\Sigma) = tr(D)$
⇒ No change.

- $Var(j^{th} PC) = P_j = \frac{\lambda_j}{trace(\Sigma)}$
⇒ 負責 P_j (proportion) 的 var.

- PC的取量？

① 通常是可以解釋總變異 70%-90%
模型 > 85% or > 90%

② 保留 eigenvalue > 平均 eigenvalue 的 PC.

③ Scree plot 斜率法：在elbow之前的那個點！（陡→平緩的）

- Σ 是用 correlation / covariance matrix?

{ correlation = 大部分 (standardized and then covariance)
covariance = 只要 variable 比例接近.

Principle Component Regression

① Standardize $X \rightarrow z_1, z_2, z_3 \dots z_m$

$$z_m = \sum_{j=1}^{p} \phi_{jm} x_j$$

ϕ_{jm}: eigenvector

(z_m 指 data 的線性組合)

根據 X 的變異大小排序

(和不是 y 的相關性)

② y 以 z 表示

$$y_i = \theta_0 + \sum_{m=1}^{M} \theta_m z_{im} + \epsilon_j$$

ϵ_j: Residual

θ_0: Regression Coefficient

$$\theta_m = \langle z_m \cdot y \rangle / \langle z_m \cdot z_m \rangle$$

z 互相獨立，更穩定

③ 把 z 代入 y

$$y_i = \theta_0 + \sum_{m=1}^{M} \theta_m z_{im} + \epsilon_j$$

$$= \theta_0 + \sum_{m=1}^{M} \theta_m \sum_{j=1}^{p} \phi_{jm} x_{ij} + \epsilon_j$$

$$= \theta_0 + \sum_{j=1}^{p} \sum_{m=1}^{M} \theta_m \phi_{jm} x_{ij} + \epsilon_j$$

$$= \theta_0 + \sum_{j=1}^{p} \beta_j x_{ij} + \epsilon_j$$

$$\beta_j = \sum_{m=1}^{M} \theta_m \phi_{jm}$$

β 數量從 $p \rightarrow M$ ($M \ll p$)

✡ OLS v.s. PCA

OLS	PCA (≠PCR)
垂直距離最小的	資料 variance 最大的方向.
以 y 為目標最佳化 ⇒ Supervised learning	與 y 無關. 看資料本身結構 ⇒ unsupervised learning.
能最好解釋 y 的線.	資料散佈最多的方向.

|| Dimension Reduction ||

解决 ① p很大 ② 高度相关 ③ OLS不稳的方法.

Ridge Regression

和OLS相同, 目的是 minimize RSS. 但有加一个惩罚. (λ)

Penalty Form

$$\hat{\beta}^{ridge} = \arg\min_{\beta} \left\{ RSS + \lambda \sum_{j=1}^{p} \beta_j^2 \right\}$$

$$= \arg\min \left\{ \sum_{i=1}^{N} y_i - \beta_0 - \sum_{j=1}^{p} \beta_j x_{ij} + \lambda \sum_{j=1}^{p} \beta_j^2 \right\}$$

$\beta_0 = \bar{y} = \frac{1}{n}\sum y$

$\lambda = 0$ OLS模型ok

$\lambda > 0$ β 越小

使用 cross validation 寻找 λ

↓ 找出min的那组β

shrinkage penalty.

Constraint Form

$$\hat{\beta}^{ridge} = \arg\min_{\beta} \{RSS\} \quad \text{subject to } \sum \beta_j^2 \le t$$

- scale dependent 尺度敏感 (PCA也是)

  要先 standardize

Matrix Form

$$\hat{\beta}^{ridge} = (X^T X + \lambda I)^{-1} X^T y$$

$\leftrightarrow$ OLS: $\hat{\beta} = (X^T X)^{-1}$

$p \times p$ identity matrix.

SVD

(把 $X = UDV^T$ 代回 $\hat{\beta}^{ridge}$)

$$\hat{\beta}^{ridge} = \sum_{j=1}^{p} u_j \frac{d_j}{d_j^2 + \lambda} u_j^T y$$

d_j 是 D 的第 j 個奇異值.

u_j 是 U 的第 j 欄的值.

shrinkage factor
- d_j 大 (高變異) → shrink 少.
- d_j 小 (低變異) → shrink 多

對低變異 (noise) 方向縮小更多 ⇒ 更穩定.

$$df(\lambda) = \sum \frac{d_j^2}{d_j^2 + \lambda}$$

- $\lambda = 0$ 時, $df = p$.
- $\lambda \to \infty$ 時, $df \to 0$.

- OLS / Ridge.

OLS	Ridge.
scale invariant 不受變數尺度影響.	scale dependent 受尺度影響
通常 Bias 較小 var 較大	通常 Bia^2 較大 var 較小 MSE 小

Lasso Regression

解決Ridge始終無法使 $\beta=0$ (會保留每個變數)

Penalty Form

$$\hat{\beta}^{lasso} = \arg\min_{\beta}\left[\sum\left(y_i-\beta_0-\sum_j x_{ij}\beta_j\right)^2+\lambda\sum_j|\beta_j|\right]$$

λ 夠大時, β_j 可能 $=0$

只挑有意義的 β 留下 $\Rightarrow$ spane model (稀疏)

Constraint Form (Lagrange Form of Lasso)

$$\hat{\beta}^{lasso} = \arg\min\sum_{i=1}^{N}\left(y_i-\beta_0-\sum_{j=1}^{p}\beta_j x_{ij}\right)^2$$

$$\text{subject to } \sum_j|\beta_j|\le t$$

no closed form, need coordinate descent.

	Ridge	Lasso
Core Value:	保留所有 β	挑有意義的 β.
Penalty Form:	$\lambda\sum\beta_j^2$	$\lambda\sum\lvert\beta_j\rvert$
畫在 x,y 軸上時:	圓滑 $\beta_0^2+\beta_1^2<t$	角多 $\lvert\beta_0\rvert+\lvert\beta_1\rvert<t$.
變數有共線性:	👑	
挑選變數		👑

Elastic-net = Lasso + Ridge

elastic net penalty $\lambda \sum_{j=1}^{p} (\alpha \beta_j^2 + (1-\alpha)|\beta_j|)$

↳ 保留变数选择 + 使高度相关的变数的影响小

(Lasso) (Ridge)

Partial least Square

→ 解决 PCA 专注於找"最能解释 X 的变异"
而不一定最能解释 y 的痛点.

- PCA 只看 X 的结构. → unsupervised.
- PLS 降维时考虑 y → supervised dimension reduction.

① 标準化 X.

② 算出 z_m

$z_m = \sum_j \phi_{mj} x_j$

向量權重 $\langle x_j, y \rangle$

<> 代表 ① 內積 ② cov ⇒ 兩向量的相似程度

③ 算出 θ_m

$\theta_m = \langle z_m, y \rangle / \langle z_m, z_m \rangle$

④ 算出下一個 y. (代入 θ_m, z_m)

$y^m = y^{m-1} + \theta_m z_m$

⑤ orthogonalization 正交化.

使更新後的 x 與目前的 z_m 沒有線性關係

因 z_m 不可重覆. 下一個 z_{m+1} 才可以從尚未解釋的部份找新的方向.

$$x_j^m = x_j^{m-1} - \frac{\langle z_m, x_j^{m-1} \rangle}{\langle z_m, z_m \rangle} z_m$$

新變數 = 舊變數 − 它在 z_m 上的投影

方法	懲罰 / 降維方式	特點	適用情況
Ridge	L2 懲罰 $\sum \beta^2$	平滑縮小係數，無變數刪除	多共線性、高維
Lasso	L1 懲罰 (\sum	\beta	)
Elastic Net	L1 + L2	同時選變數與群組化	高度相關特徵
PCR	PCA 對 X	無監督降維	探索性分析
PLS	同時考慮 X, y	監督降維，預測力強	高維預測問題

方法	懲罰或降維方式	主要效果	適用情況
Ridge Regression	L2 懲罰 $\lambda \sum \beta_j^2$	係數縮小但不為 0	多重共線性、高維資料
Lasso Regression	L1 懲罰 (\lambda \sum	\beta_j	)
Elastic Net	混合 L1 + L2 懲罰	同時群組與刪除變數	高度相關變數群
PCR	對 X 做 PCA（不考慮 y）	無監督降維	探索性分析
PLS	同時考慮 X 與 y 的相關方向	有監督降維、預測力強	高維預測問題

方法	對各方向的處理	數學上的行為	結果特性
Ridge	平滑地縮小所有方向	$\frac{d_j^2}{d_j^2+\lambda}$	連續 shrink，全都非 0
PCR	保留前 M 個方向、丟掉其他	像 step function	只用高變異方向
PLS	根據與 y 的關聯動態縮放	shrink 有時 <1，有時 >1	有時放大、非單調

12 Support Vector Machine

- Maximal Margin Classifier 理論上完美的線性邊界
- Support Vector Classifier 允許少量錯誤，提升穩定性
- Support Vector Machine 用kernel把線性問題推到非線性邊界

Maximal Margin Classifier

一選距離最近資料點最遠的線 (maximize margin) 中間不色地帶最寬的線

Hyperplane 超平面：n維空間中 n-1 維的子空間

$\beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_{n-1} X_{n-1} = 0$

→ 代入向量後 { =0 → 點在Hyperplane上
>0 or <0 → 點在左右兩側

邊界寬度 (margin)

$$\underset{\beta_0, \beta_1, \ldots \beta_p}{\text{Maximize}} \ M \quad \text{subject to } \sum \beta_j^2 = 1$$

$$y_i(\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots \beta_p x_p) \geq M$$

Support Vector Classifier = soft margin (有邊界不是絕對的)

解決現實問題大多無法用直線絕對的分類

slack variable 允許的違規量

$$\underset{\beta_0 \ldots \beta_p}{\text{Max}} \ M \quad \text{subject to } \sum \beta_j^2 = 1$$

$$y_i(\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_p x_p) \geq M(1 - \epsilon_i)$$

$\epsilon_i \geq 0$, $\sum \epsilon_i \leq C$

- $\epsilon_i = 0$ 對的一邊 margin
- $\epsilon_i > 0$ 錯的一邊 margin？
- $\epsilon_i > 1$ 錯的一邊 hyperplane

懲罰強度

- C大：模型傾向硬邊界 高var / 低bias
- C小：more soft 低 / 高

Support Vector Machine = SVC + Kernel

加入高次項(複雜化)使非線性可用線性解釋

$$\text{Max } M \quad \text{subject to } y_i(\beta_0 + \sum \beta_{j1} x_{ij} + \sum \beta_{j2} x_{ij}^2) \geq M(1-\epsilon_j)$$

加入的高次項

$$\epsilon_j \geq 0, \quad \sum \epsilon_j \leq C \quad \sum \sum_{k=1}^{2} \beta_{jk}^2 = 1$$

Kernel approach

相似度關聯.

用一個函數K代表內積,模擬在高維空間裡的Result.

可以不用實際把複雜的高次項算出來.

$$SVC \rightarrow f(x) = \beta_0 + \sum_{i=1}^{n} \alpha_i \langle X, X_i \rangle$$

$\alpha > 0$ 是 support vector

$$= \beta_0 + \sum \alpha_i K(X, X_i)$$

$$\begin{cases} \text{linear Kernel} = \sum_{j=1}^{p} x_{ij} x_{i'j} \\ \text{Polynomial Kernel} = (1 + \sum x_{ij} x_{ij})^d \\ \text{Radical Basis Function} = \exp(-\gamma \sum (x_{ij} - x_{ij})^2) \end{cases}$$

γ 正的常數項

↓

RBF ≈ 距離權重

距離近的樣本影響大,遠的沒影響.

SVM Parameter
- C
- kernel
  - d
  - γ

SVM → binary

→ multiple? →
- one v.s. all.
- one v.s. one.

13 Support Vector Machine II

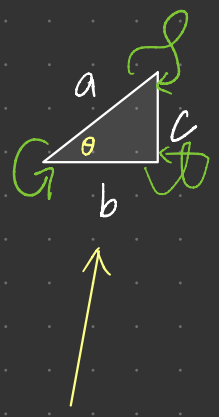

$\sin = \frac{c}{a}$

$\cos = \frac{b}{a}$

$\tan = \frac{c}{b}$

Vector 基本知識

① dot product 內積 = inner product

$a \cdot b = |a||b| \cdot \cos\theta$ $\vec{a}$ $\vec{b}$ 夾角

- $\theta < 90°$ $\cos > 0$
- $\perp$ $\cos = 0$
- $\theta > 90°$ $\cos < 0$

② cross product 外積

外積向量 $\perp$ $\vec{a}$, $\vec{b}$

$a \cdot b = |a| \cdot |b| \cdot \sin\theta$

③ normal vector 法向量

$\perp$ 於平面上任一向量的一向量

④ scalar equation of plane 純量方程式

用內積，將空間任一點及法向量的關係表現出來

↳ 題目給3點，可算出2向量，法向量

Hyperplane

每個平面都可以用一個向量 w 來定義它的方向

平面上的任意點 (x_1, x_2, x_3) (也是一向量)

平面的法向量 $w^T x + b = 0$

$w = (a, b, c)$

intercept

x_0 到平面 w 距 $= \dfrac{w^T x_0 + b}{|w|}$

兩平面 w_1 w_2 距 $= \dfrac{b_1 - b_2}{|w|}$

流程 如何 classify 一組 data？

① select two hyperplane → 對於每個 data：(either)

$$\begin{cases} w x_i + b \geq 1 & \text{class } 1 \\ w x_i + b \leq 1 & \text{class } -1 \end{cases}$$

$$\begin{cases} H_0 : w^T x + b = 1 \\ H_1 : w^T x + b = -1 \end{cases}$$

② Maximize hyperplane

$$m = \frac{2}{|w|}$$

Optimization

Max $\dfrac{2}{|w|}$ 相當於 mini $|w|$

Hard Margin SVM

$$\text{Mini } \frac{1}{2}|w|^2$$

subject to $y_i(w \cdot x_i) + b \geq 1 \quad i = 1 \cdots n.$

Lagrange Multiplier Method.

解決上一則公式不好用的問題.

$$L(w, b, \alpha) = \frac{1}{2}|w|^2 - \sum \alpha [y_i (w^T x_i + b) - 1]$$

$$\alpha_i \geq 0$$

Wolfe dual Problem

Lagrange 的對偶問題

$$\max W(\alpha) = \sum \alpha - \frac{1}{2} \sum\sum \alpha_i \alpha_j y_i y_j (x_i^T x_j)$$

$$\text{subject to } \alpha_i \geq 0 \quad \sum \alpha_i y_i = 0$$

Soft margin SVM

$$\min \frac{1}{2}|w|^2 + C \sum \xi_i$$

$$\text{subject to } y_i (w \cdot x_i + b) \geq 1 - \xi_i$$

$$\xi_i \geq 0$$

+ Wolfe dual

$$\max \sum \alpha_i - \frac{1}{2} \sum\sum \alpha_i \alpha_j y_i y_j x_i \cdot x_j$$

$$\text{subject to } 0 \leq \alpha \leq C$$

$$\sum \alpha_i y_i = 0$$

+ kernel

$$\min \frac{1}{2} \sum\sum \alpha_i \alpha_j y_i y_j k(x_i, x_j) - \sum \alpha$$

$$\text{subject to } 0 \leq \alpha \leq C$$

$$\sum \alpha_i y_i = 0$$

14 Neural Network I

- Neurons

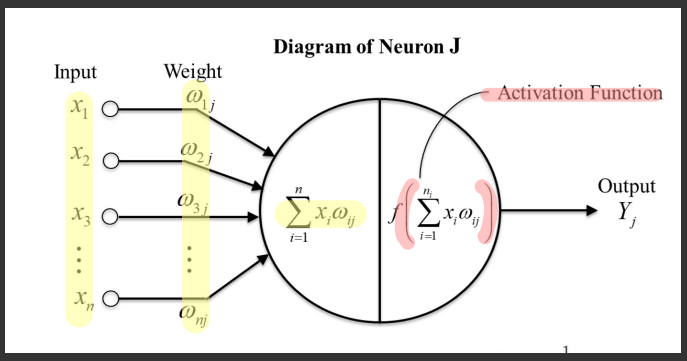

{ Sigmoid = 0-1類似logistic
ReLU = Preferred 👑

$Y_j = f(\sum_i w_{ij} x_i)$ = 線性組合 + 非線性組合.

Single layer NN

$$f(x) = \beta_0 + \sum_{k=1}^{K} \beta_k \, g(w_{k0} + \sum_{j=1}^{P} w_{kj} x_j)$$

$X_1 \cdots X_j$ 丟進 hidden layer

$$= \beta_0 + \sum \beta_k h_k(X)$$

$$= \beta_0 + \sum \beta_k A_k$$

hidden layer 結果丟進 output layer

= minimize Loss Function.

= find Optimal weight Matrix.

NN 訓練目標

quantitative (regression) = squared-error loss. (MSE)

$$L(\theta \mid X) = \sum_{i=1}^{n} (y_i - f_\theta(x_i))^2$$

qualitative (classify) = multinomial log-likelihood. (cross entropy)

$$L(\theta \mid X) = -\sum_{i=1}^{n} \sum_{m=1}^{M} y_{im} \log(f_m(x_i))$$

y_{im}: label; $f_m(x_i)$: output = prob. of class.

Multilayer NN

相對於 single layer:

① 學到分層特徵.

② 用較少的 neuron 達到更好的效率.

Loss Function

- Nonconvexity 非凸的 (=多重非線性)
- Many local minima
- SGD 可找到合理的 local minima.

Back Propogation

① Forward Pass.

input → hidden layer → output

算出所有的 H_i 和 A_i.

② Compute Loss.

比較 discrepency = output − target value.

$$E = \frac{1}{2}\sum_k (T_k - O_k)^2$$ → Reduce E

① Gradient Descent.

② Take 一階偏導數 with respect of weights.

③ 修正 w_{ij} 和 w_{jk}.

③ Backward Pass.

output → hidden layer → input.

用 chain rule 計算每個權重的偏導數

Objective Function. △θ個 △R(θ)個

$$\begin{aligned}\frac{\partial R_i(\theta)}{\partial w_{kj}} &= \frac{\partial R_i(\theta)}{\partial f_\theta(x_i)} \cdot \frac{\partial f_\theta(x_i)}{\partial g(z_{ik})} \cdot \frac{\partial g(z_{ik})}{\partial z_{ik}} \cdot \frac{\partial z_{ik}}{\partial w_{kj}} \\ &= -(y_i - f_\theta(x_i)) \cdot \beta_k \cdot g'(z_{ik}) \cdot x_{ij}.\end{aligned}$$

④ 用 Gradient Descent adjust the weight matrix.

$$W_{new} = W_{old} - p\frac{\Delta E}{\partial W} = \delta \text{ (vector)}$$

(Gradient Descent)

$$\theta_{n+1} = \theta_n + \text{learning rate} \cdot \text{Gradient}$$

Hyperparameter

① # of layers.

② # of Neurons in each layer

- input + output = $\frac{2}{3}$ of all.
- hidden layer = no rules.

③ Learning rate.

④ Cross-validation.

Typical
- 50% training
- >5% each for validation and testing.

Overfitting

Avoid : ① SGD

Methods 用 minibatch 有 noise, → 可以 avoid saddle point.

② Regularization.

Ridge / lasso → Penalty Form.

③ Early stopping.

④ Dropout Learning.

15 Neural Network II

Convolutional Neural Network = CNN

- Compared to conventional NN
  - ① size could be much larger.
  - ② Not fully connected.
  - ③ local features: low level feature,
    ↓
    compound features: high level feature,

- Input layer
  Hidden layer
  Output layer
  - Hidden layer:
    - convolution layer = search for small patterns.
    - pooling layer = reduce dimension to select a prominent subset.

Convolution 卷積

- Convolution (v.) = cross-correlation.
  = Filter 滑動 + 元素相乘相加,
  ↳ 類似內積? 轉換矩陣?
- Filter =
  - image $h \times w \times d$.
  - filter $f_h \times f_w \times d$. 輸入的深度必須一致.
  - ↓ (各 dimension 相減加一)
  - Feature map $(h-f_h+1) \times (w-f_w+1) \times 1$

※ filter 經過 convolution → Feature map.

通常使用 ReLU "Feature detector layer" 可以讓模型擬合更複雜的關係

input —convolution→ Convolution layer (N Filters) —Activate Function→ Output.

↓

$(h-f_h+1) \times (w-f_w+1) \times N$

N個 Feature Map.

- Advantages：

① Reduces Parameters (shared filtered weight)

② Preserves Locality (空間位置資訊)

靠近的 pixels - 起被辨識.

- Stride 步幅.

{ 大：輸出小，運算快.
  小：輸出細緻，尺寸大.

- padding 補 0

① zero padding. = Same padding

把圖像外圍補 0.

② valid padding

只計算 filter 能完整放上的区域.

- Activation Function：ReLU（非線性）

= Rectified Linear Unit

$f(x) = \max(0, x)$

所有負值變成 0　保留正值（特徵有被偵測到）

優点 ① 計算快速

② 不會像 sigmoid / tanh - 梯度消失.

Pooled 池化

= subsampling = downsize sampling.

- Reduce dimensionality of feature matrix, while retain important info.
  ↳ location invariance 位置不敏感.

original matrix (4×4) → finished matrix (2,2)
×1/2

Data Augmentation 資料增強.

訓練時加入一些變形→增強模型的泛化能力.

優点: ①視作一种Regulization.
模型會学到形狀大概長怎樣.

② 搭配SGD (小批次訓練) 非常好.
↳ stochatic gradient descent.

Architecture.

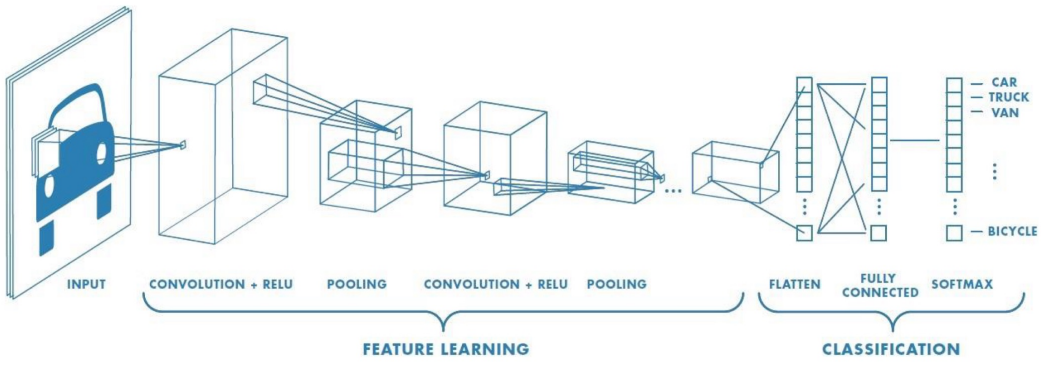

Examples of Complete CNN Architecture

Recurrent Neural Network.

- CNN = 處理 spatial patterns. (空間結構)
- RNN = 處理 temporal patterns. (時間結構, 順序資訊)

output (O_t) = input (X_t) + hidden layer (A_{t-1})

使用同一組權重, 只是運行多次了

有資料是記憶.

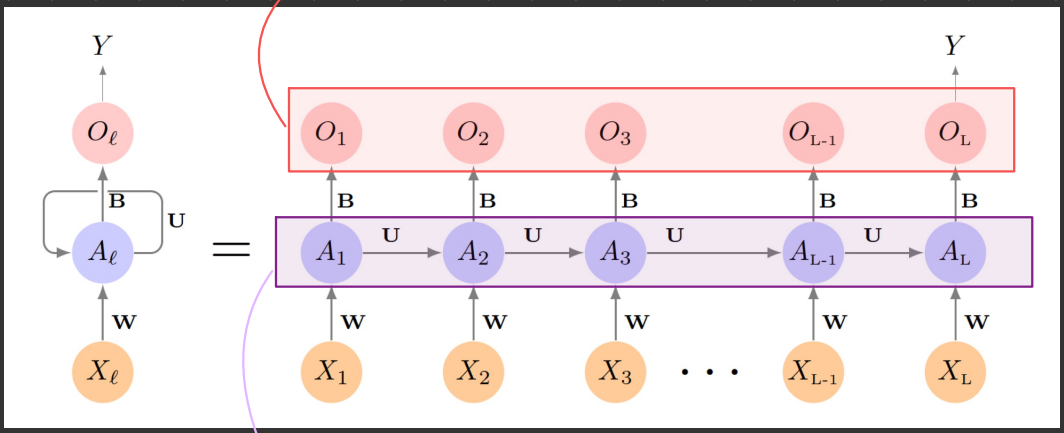

hidden layer

Activation Function

from previous step.

$$A_{\ell k} = g\left(w_{k0} + \sum_{j=1}^{p} w_{kj} X_{\ell j} + \sum_{s=1}^{K} u_{ks} A_{\ell-1,s}\right)$$

Output

$$O_\ell = \beta_0 + \sum_{k=1}^{K} \beta_k A_{\ell k}$$

Loss function

Minimize =

$$\sum_{i=1}^{n} (y_i - o_{iL})^2 = \sum_{i=1}^{n} \left(y_i - \left(\beta_0 + \sum_{k=1}^{K} \beta_k g\left(w_{k0} + \sum_{j=1}^{p} w_{kj} x_{iLj} + \sum_{s=1}^{K} u_{ks} a_{i,L-1,s}\right)\right)\right)^2.$$

缺点：① 难训练.

② backpropogation 会造成梯度越来越小.

③ Long Term pattern 难学习. (50+ step)

Long Short-Term Memory (LSTM) Models.

解决RNN会梯度消失和无法学会 long pattern.

→引入 gating.

further back activation

previous activation.

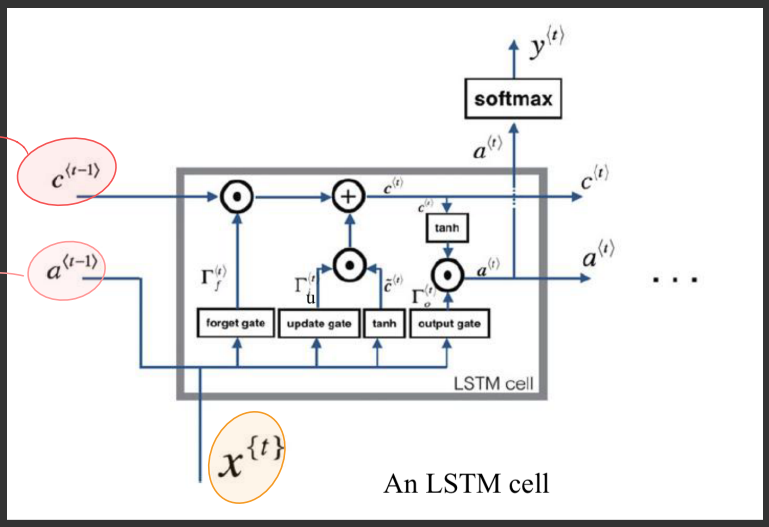

current input

ELMAN NN 👑 prediction of sequence / time series.

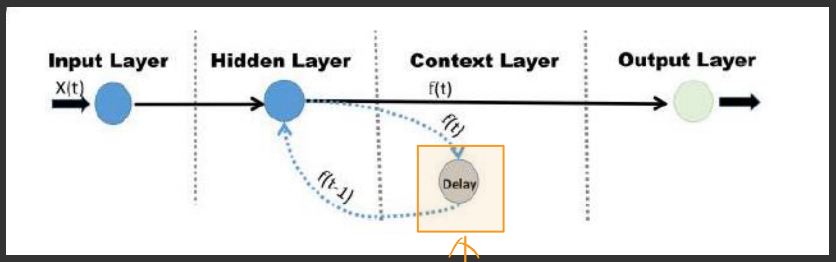

会延迟一步回传 activation.

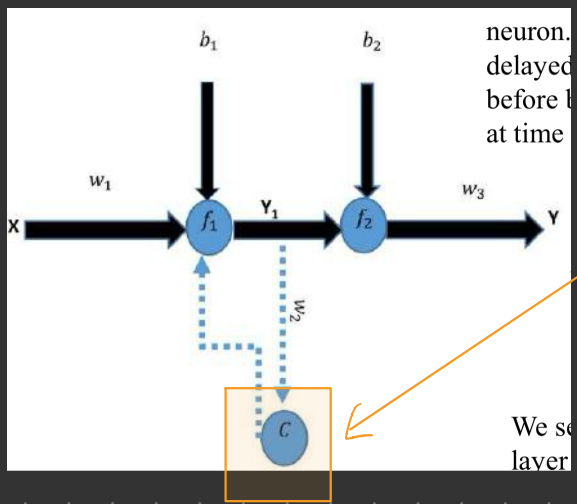

C是回传 t-1 的

$$Y[t] = f_2\left(w_3 f_1\left(w_1 X[t] + w_2 C + b_1\right) + b_2\right)$$

where,

$$C = Y_1[t-1]$$

有 neuron 有权重.

JORDAN NN

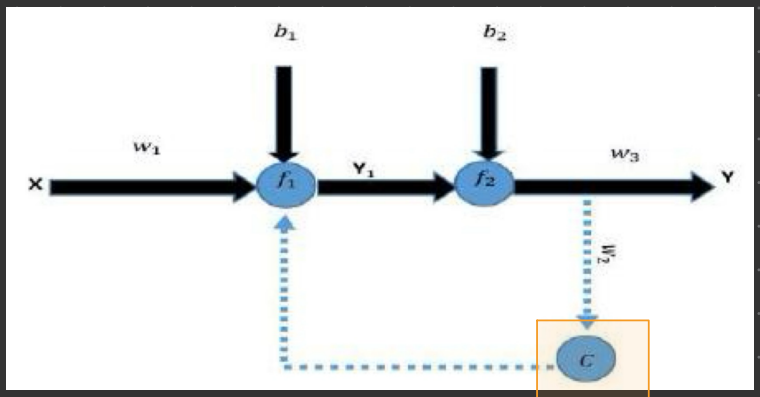

context neurons
是儲存前一個 output

特性	Elman	Jordan
回饋來源	Hidden layer	Output
記憶內容	隱藏狀態（較深層特徵）	預測結果（較表層）
記憶能力	比較長	比較短
應用	語言建模、複雜序列	時序分類、控制系統

Restricted Boltzmann Machines.

- deep belief network (DBN) = multilayer RBM
- 是学習事情發生的机率.

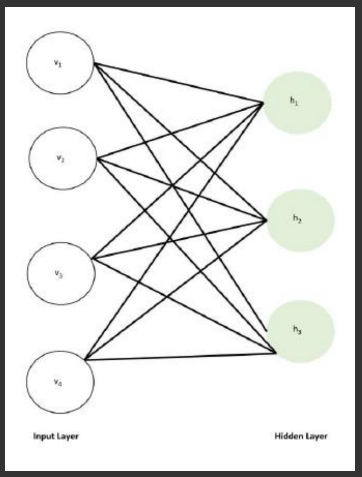

- 每個 v 都連線到每個 h
但 v, h 自己互不相連 → independent.

- energy-based model

$$P(v,h) = \frac{1}{Z}\exp -\tilde{E}(v,h)$$

$\tilde{E}(v,h)$ 越小 → $P(v,h)$ 越大

$$Z = \sum_{v}\sum_{h}\exp -\tilde{E}(v,h)$$

Z 是所有 (v,h) 的 sum. $P(Z)=1$.

$$\tilde{E}(v,h) = -\sum_{i=1}^{m}\sum_{j=1}^{n} w_{ij}v_i h_j - \sum_{i=1}^{m} v_i b_i - \sum_{j=1}^{n} h_j d_j$$

visible / hidden interaction

visible bias

hidden bias.

v 和 h 同時出現機率高.

w 个 $\tilde{E}$ ↓ 組合更容易被生成

Entropy (play golf) = (9,5) = (0.64, 0.35).

$= -0.64 \log 0.64 - 0.35 \log 0.35$.

$= 0.4128 + 0.5301 = 0.942$.

Weighted Entropy = (3,2) = (0.6, 0.4)

$= 0.4421 + 0.5287$.

$= 0.9708$.

Info gain = 0.0088.

$5 \times 0.6792 (1 - 0.6792)$ $\left[\sum (0.6636 - 1)\ 0.6636.\ (1 - 0.6636).\ 0.5\right]$

$= 1.0894$.

0.0375

$\chi_{ij} =$